




Тверской
государственный
технический
университет


Интеллектуальные информационные системы

Линейные модели


2026 г.



Employers
when you tell
them your app
uses linear
regression




Employers
when you tell
them your app
uses “machine
learning and
A.I.”




$$y = \langle x, w \rangle + w_0$$



Classification



Regression



Линейная регрессия

Линейная регрессия – метод предсказания вещественного выходного значения (целевой переменной) $y \in \mathbb{R}$ по вектору вещественных входных значений (признаков) $x \in \mathbb{R}^D$, при предположении, что ожидаемое выходное значение описывается линейной функцией входных значений

$$y(x) = w_0 + \sum_{i=1}^d w_i x_i$$



w_0 - свободный
коэффициент (сдвиг,
bias)

w_i - параметры модели
(коэффициенты, веса)

Пример: стоимость дома

x_1 - площадь дома, м²

x_2 - расстояние до центра, км.

y - стоимость, млн ₽.

Площадь, м ²	До центра, км	Стоимость, млн ₽
80	5	8,6
120	10	11,3
160	20	14,8

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 = 2 + 0,09x_1 - 0,1x_2$$

Дом 120 м² в 10 км от центра: $\hat{y} = 11,8$ млн ₽.

Предсказание и ошибка

Модель выдаёт $\hat{y}_i$, а в выборке известна стоимость y_i .

$$e_i = \hat{y}_i - y_i$$

Дом 120 м² в 10 км от центра:

прогноз 11,8 млн ₽, фактическая стоимость 11,3 млн ₽.

$$e = 11,8 - 11,3 = 0,5 \text{ млн } \text{₽}$$

Положительная ошибка: завысили стоимость.

Отрицательная ошибка: занизили стоимость.

Измерение ошибки в задачах регрессии

$$MSE = \frac{1}{l} \sum_{i=1}^l (\hat{y}_i - y_i)^2$$

Квадрат ошибки сильнее штрафует большие отклонения


$$MAE = \frac{1}{l} \sum_{i=1}^l |\hat{y}_i - y_i|$$

Абсолютная ошибка меньше реагирует на выбросы

$$RMSE = \sqrt{\frac{1}{l} \sum_{i=1}^l (\hat{y}_i - y_i)^2}$$

l — число объектов. MAE и RMSE измеряются в единицах y , MSE — в квадрате этих единиц.


Как штрафуем за ошибку



Измерение ошибки в задачах регрессии

- $MSE(\mathbf{y}, \hat{\mathbf{y}}) = \frac{1}{l} \sum_{i=1}^l (\hat{y}_i - y_i)^2$
- $MAE(\mathbf{y}, \hat{\mathbf{y}}) = \frac{1}{l} \sum_{i=1}^l |\hat{y}_i - y_i|$
- $MAPE(\mathbf{y}, \hat{\mathbf{y}}) = \frac{1}{l} \sum_{i=1}^l \frac{|\hat{y}_i - y_i|}{y_i} \times 100\%$
- $RMSE(\mathbf{y}, \hat{\mathbf{y}}) = \sqrt{\frac{1}{l} \sum_{i=1}^l (\hat{y}_i - y_i)^2}$
- $MSLE(\mathbf{y}, \hat{\mathbf{y}}) = \frac{1}{l} \sum_{i=1}^l (\log(1 + \hat{y}_i) - \log(1 + y_i))^2$



Измерение ошибки в задачах регрессии



Измерение ошибки в задачах регрессии

Coefficient of determination

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^l (\hat{y}_i - y_i)^2}{\sum_{i=1}^l (y_i - \bar{y})^2}$$



R^2 и объяснённая дисперсия

R^2 показывает, насколько модель уменьшает сумму квадратов ошибок по сравнению с постоянным прогнозом $\bar{y}$.

$$R^2 = 1 - \frac{\sum_{i=1}^l (\hat{y}_i - y_i)^2}{\sum_{i=1}^l (y_i - \bar{y})^2}$$

Для МНК со свободным членом на обучающей выборке общая вариация равна сумме объяснённой и остаточной. Тогда R^2 — доля дисперсии y , объяснённая моделью.

Например, $R^2 = 0,8$ означает 80% объяснённой дисперсии. Это не доля правильных ответов и не доказательство причинности.


На test R^2 может быть отрицательным: модель хуже среднего. При постоянном y стандартная формула не определена.

Измерение ошибки в задачах регрессии

Symmetric mean absolute percentage error:

$$SMAPE^{0-100}(y, \hat{y}) = \frac{100\%}{l} \sum_{i=1}^l \frac{|\hat{y}_i - y_i|}{(|y_i| + |\hat{y}_i|)}$$


$$SMAPE^{0-200}(y, \hat{y}) = \frac{100\%}{l} \sum_{i=1}^l \frac{|\hat{y}_i - y_i|}{(|y_i| + |\hat{y}_i|)/2}$$



Функция потерь Хьюбера

$$L_{\delta}(e) = \frac{e^2}{2} \quad \text{при } |e| \leq \delta$$

$$L_{\delta}(e) = \delta(|e| - \frac{\delta}{2}) \quad \text{при } |e| > \delta$$




При малых ошибках потеря квадратичная, при больших — линейная. Порог $\delta > 0$ определяет переход между этими режимами.

Измерение ошибки в задачах регрессии

Quantile Loss

$$Q(y, \hat{y}) = \frac{1}{l} \sum_{i=1}^l \rho_{\tau}(y_i - \hat{y}_i)$$



Линейная модель в матричном виде

$$\hat{y}_i = w_0 + \sum_{j=1}^d w_j x_{ij}$$

В X одна строка на объект.

Первый столбец состоит из единиц.

Вектор w содержит свободный член w_0 и веса признаков.

$$w = (w_0, w_1, \dots, w_d)^T \quad \hat{y} = Xw$$

$$L(w) = \frac{1}{l} \|Xw - y\|^2 \rightarrow \min_w$$

Обучение линейной регрессии

Задача оптимизации:

$$\frac{1}{l} \sum_{i=1}^l (\langle \mathbf{w}, \mathbf{x}_i \rangle - y_i)^2 \rightarrow \min_{\mathbf{w}}$$

В матричном виде:

$$\frac{1}{l} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 \rightarrow \min_{\mathbf{w}}$$

Решение:

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Метод наименьших квадратов

Находим вектор весов w , при котором градиент $L(w)$ равен нулю.

$$\nabla L(w) = \frac{2}{l} X^T (Xw - y) = 0$$

$$X^T X w = X^T y$$

$$w = (X^T X)^{-1} X^T y$$

Формула с обратной матрицей требует независимых столбцов X .

На практике решаем задачу через QR или SVD, без явного вычисления обратной матрицы.

Градиентные методы оптимизации

Градиент функции $f : \mathbb{R}^n \rightarrow \mathbb{R}$ - вектор частных производных

$$\nabla f(x_1, \dots, x_n) = \left(\frac{\partial f}{\partial x_j} \right)_{j=1}^n$$


Градиентный шаг:

$$\mathbf{w}^{(k)} = \mathbf{w}^{(k-1)} - \alpha \nabla Q(\mathbf{w}^{(k-1)})$$

$\mathbf{w}^{(0)}$ - начальный набор параметров

$Q(\mathbf{w})$ - значение функционала ошибки для набора параметров $\mathbf{w}$

α - learning rate (размер шага, темп обучения)




Оценивание градиента

- Полный градиент:

$$\nabla_w Q(w) = \frac{1}{l} \sum_{i=1}^l \nabla_w q_i(w)$$

- Стохастический градиентный спуск (SGD):

$$w^{(k)} = w^{(k-1)} - \alpha \nabla q_{i_k}(w^{(k-1)})$$



- Средний стохастический градиент (SAG):

$$w^{(k)} = w^{(k-1)} - \alpha \frac{1}{l} \sum_{i=1}^l z_i^{(k)}$$

Full-batch, SGD и mini-batch

Full-batch: обычный градиентный спуск.

Каждый шаг использует все объекты обучающей выборки.

SGD: каждый шаг использует один случайный объект.

Градиент дешевле вычислить, но оценка получается шумной.

Mini-batch: каждый шаг использует B объектов, где $1 < B < I$.

Например, при $I = 3200$ и $B = 32$ получаем 100 шагов за эпоху.

Batch — общее название группы объектов.

В коде и документации этим словом часто называют именно mini-batch.

Модификации градиентного спуска

- Метод инерции (momentum):

$$\mathbf{w}^{(k)} = \mathbf{w}^{(k-1)} - \mathbf{h}_k$$

$$\mathbf{h}_k = \beta \mathbf{h}_{k-1} + \alpha \nabla_{\mathbf{w}} Q(\mathbf{w}^{(k-1)})$$


вектор инерции


параметр метода, определяющий
скорость затухания градиентов с
предыдущих шагов

- Nesterov momentum:

$$\mathbf{h}_k = \beta \mathbf{h}_{k-1} + \alpha \nabla_{\mathbf{w}} Q(\mathbf{w}^{(k-1)} + \beta \mathbf{h}_{k-1})$$

Adaptive learning rate

- Adagrad

$$G_{k+1} = G_k + (\nabla f(x_k))^2$$
$$x_{k+1} = x_k - \frac{\alpha}{\sqrt{G_{k+1} + \varepsilon}} \nabla f(x_k).$$

- RMSProp

$$G_{k+1} = \gamma G_k + (1 - \gamma)(\nabla f(x_k))^2$$
$$x_{k+1} = x_k - \frac{\alpha}{\sqrt{G_{k+1} + \varepsilon}} \nabla f(x_k).$$

- Adam (ADaptive Momentum)

$$v_{k+1} = \beta_1 v_k + (1 - \beta_1) \nabla f(x_k)$$
$$G_{k+1} = \beta_2 G_k + (1 - \beta_2)(\nabla f(x_k))^2$$
$$x_{k+1} = x_k - \frac{\alpha}{\sqrt{G_{k+1} + \varepsilon}} v_{k+1}.$$

Регуляризация

- При наличии в выборке линейно зависимых (мультиколлинеарных) признаков всегда найдется такой вектор $\mathbf{v}$, что для любого объекта $\mathbf{x}$:

$$\langle \mathbf{v}, \mathbf{x} \rangle = 0$$

Множество решений:

$$\langle \mathbf{w} + \alpha \mathbf{v}, \mathbf{x} \rangle = \langle \mathbf{w}, \mathbf{x} \rangle + \alpha \langle \mathbf{v}, \mathbf{x} \rangle = \langle \mathbf{w}, \mathbf{x} \rangle$$

тоже решение
оптимизационной задачи
для любого α

оптимальный вектор весов
(решение оптимизационной задачи)

Подмена задачи:

$$Q_{\lambda}(\mathbf{w}) = Q(\mathbf{w}) + \lambda R(\mathbf{w})$$

коэффициент
регуляризации

регуляризатор

- L_1 -регуляризация:

$$R_1(\mathbf{w}) = \|\mathbf{w}\|_1 = \sum_{i=1}^d |\mathbf{w}|_i$$

- L_2 -регуляризация:

$$R_2(\mathbf{w}) = \|\mathbf{w}\|_2 = \sum_{i=1}^d w^2$$

- Elastic net regularization:

$$R_E(\mathbf{w}) = R_1(\mathbf{w}) + R_2(\mathbf{w})$$

Преобразования признаков


Нелинейные преобразования исходного признакового пространства вида

$$x = (x_1, \dots, x_d) \rightarrow \varphi(x) = (\varphi_1(x), \dots, \varphi_m(x))$$

- Полиномиальное (квадратичные или более высоких порядков): $\varphi(x) = (x_1, \dots, x_d, x_1^2, \dots, x_d^2, x_1 x_2, \dots, x_{d-1} x_d)$
- Логарифмическое: $\log(x_i)$
- Экспоненциальное: $\exp(\frac{\|x - \mu\|^2}{\sigma})$
- Синусоидальное: $\sin(x_i / T)$
- Любое другое, если вы можете обосновать и реализовать это преобразование

Линейная регрессия с преобразованием признаков


Реальная
зависимость



$$y = f(x) + \varepsilon$$

Кривая $f(x)$ и наблюдения


Исходный
признак x



$$\hat{y} = w_0 + w_1x$$

Прямая не описывает
нелинейную зависимость

Добавляем
признаки x^2 и x^3



$$\hat{y} = w_0 + w_1x + w_2x^2 + w_3x^3$$

Масштабирование признаков

- Стандартизация (standard scaling):

$$z = \frac{x - \mu}{\sigma}$$

- Масштабирование к диапазону $[a, b]$ (min-max normalization):

$$x' = a + \frac{(x - \min(x))(b - a)}{\max(x) - \min(x)}$$

- Robust scaling (standardization using median and IQR):

$$x' = \frac{x - Q_2(x)}{Q_3(x) - Q_1(x)}$$