



Тверской
государственный
технический
университет

Интеллектуальные информационные системы


Метод опорных векторов
Решающие деревья

2026 г.


Метод опорных векторов в задачах классификации

Предположим, что выборка линейно разделима:

$$Q(w, w_0) = \sum_{i=1}^l [y_i(\langle w, x_i \rangle - w_0) < 0] = 0$$



Ширина полосы: $\left\langle (x_+ - x_-), \frac{w}{\|w\|} \right\rangle = \frac{2}{\|w\|}$



Для линейно разделимой выборки:

Классификация с жестким зазором (hard margin)

$$\begin{cases} \frac{1}{2} \|w\|^2 \rightarrow \min_{w, w_0} \\ M_i(w, w_0) \geq 1, i = 1, \dots, l \end{cases}$$

Обобщение для линейно неразделимой выборки:


Классификация с мягким зазором (soft margin) – максимизируем зазор, но допускаем его нарушение некоторыми объектами

$$\begin{cases} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^l \xi_i \rightarrow \min_{w, w_0, \xi} \\ M_i(w, w_0) \geq 1 - \xi_i, \quad i = 1, \dots, l \\ \xi_i \geq 0, \quad i = 1, \dots, l \end{cases}$$


ξ_i — величина ошибки на объектах x_i

C — штраф за суммарную ошибку, чем больше значение тем сильнее штраф

Hard Margin



Soft Margin



+ Class 1


• Class 2

⊙ ⊕ Support Vectors

⊙ ⊕ Points violating constraint

Функция потерь и регуляризация в SVM


$$C \sum_{i=1}^l (1 - M_i(w, w_0))_+ + \frac{1}{2} \|w\|^2 \rightarrow \min_{w, w_0}$$



Нелинейное обобщение SVM

Идея: переход от исходного пространства признаков описаний объектов X к новому пространству H (спрямляющему пространству) с помощью некоторого преобразования $\psi: X \rightarrow H$

Kernel trick (ядерный трюк) – вычисляет скалярное произведение объектов в преобразованном пространстве без явного построения новых признаков



- Линейное ядро:

$$K(x, x^T) = \langle x, x^T \rangle$$

- Квадратичное ядро:

$$K(x, x^T) = \langle x, x^T \rangle^2$$

- Полиномиальное ядро:


$$K(x, x^T) = (\langle x, x^T \rangle + 1)^d$$

- Гауссовское RBF ядро (радиально-базисная функция):

$$K(x, x^T) = \exp(-\gamma \|x - x^T\|^2)$$

- Сигмоидальное ядро:

$$K(x, x^T) = \tanh(k_1 \langle x, x^T \rangle - k_0), \quad k_0, k_1 \geq 0$$




Метод опорных векторов в задачах регрессии

Модель регрессии:

$$a(x) = \langle x, w \rangle - w_0, \quad w \in \mathbb{R}^n, \quad w_0 \in \mathbb{R}$$

Функция потерь: $L(\varepsilon) = (|\varepsilon| - \delta)_+$

Кусочно-линейная функция ε -чувствительности




Смысл функции потерь – если мы находимся на расстоянии не более чем δ от правильного ответа, то потери нет, за такой ответ не штрафует. Если дальше, то штраф увеличивается линейно.

Постановка задачи (с L2-регуляризацией):

$$\sum_{i=1}^l (|\langle \mathbf{w}, \mathbf{x}_i \rangle - w_0 - y_i| - \delta)_+ + \frac{1}{2C} \|\mathbf{w}\|^2 \rightarrow \min_{\mathbf{w}, w_0}$$

Решающие деревья



Решающее дерево – конечный связный граф с множеством вершин V , не содержащий циклов и имеющий выделенную вершину (корень дерева) $v_0 \in V$, в которую не входит ни одно ребро. Вершина, не имеющая выходящих ребер, называется терминальной или листом. Остальные вершины называются внутренними

Бинарное решающее дерево – решающее дерево, в котором каждой внутренней вершине $v \in V$ приписан предикат (функция) $\beta_v : X \rightarrow \{0, 1\}$ и каждой терминальной вершине приписан ответ: класс (для классификации) или число (для регрессии)

Предикат – логическое выражение или условие, которое используется в узле решения для выбора ветви. Могут быть как одномерные, так и многомерные.

- Одномерные предикаты – сравнивают значение одного из признаков с порогом:



$$\beta_v(x; j, t) = [x_j < t]$$

- Многомерные предикаты – используют несколько признаков. Например, линейный многомерный предикат записывается как:

$$\beta_v(x) = [\langle w, x \rangle < t]$$



Decision tree classifier on Iris data

Depth = 2




Decision tree classifier on Iris data


Depth = 3




Decision tree classifier on Iris data

Depth unrestricted





Decision Tree Regression



Построение решающих деревьев

X – исходное множество объектов обучающей выборки

X_m – множество объектов, попавших в текущий лист

Жадный алгоритм:

1. Создаем вершину v
2. Если выполнен критерий остановки ***Stop***(X_m), то останавливаемся, объявляем эту вершину листом и ставим ей в соответствие ответ ***Ans***(X_m) и возвращаем ее
3. Иначе: находим предикат $B_{j,t}$, который определит наилучшее разбиение текущего множества объектов X_m на две подвыборки X_l и X_r , максимизируя критерий ветвления ***Branch***(X_m, j, t)
4. Для X_l и X_r рекурсивно повторяем процедуру

- Критерий остановки ***Stop***(X_m) – функция, которая решает, нужно ли продолжать ветвление
- Функция ***Ans***(X_m) – вычисляет ответ для листа по попавшим в него объектам из обучающей выборки. Для классификации - метка самого частого класса, оценка дискретного распределения вероятностей, для регрессии – среднее при MSE, медиана при MAE.
- Критерий ветвления ***Branch***(X_m, j, t) – функция, измеряющая, насколько хорош предлагаемый сплит. Чаще всего оценивает уменьшение неоднородности узлов дерева в случае, если получившиеся два листа будут терминальными, в сравнении с ситуацией, когда сама исходная вершина будет листом. Выбирается сплит, который дает наиболее существенное улучшение

Критерий ветвления определяется оценкой
критерия информативности (impurity):

$$H(X_m) = \min \frac{1}{|X_m|} \sum_{(x_i, y_i) \in X_m} L(y_i, c)$$

c – ответы дерева, $c \in R$ для регрессии и меток класса, для дискретного распределения на классах $c \in R^K$ вектор вероятностей $c = (c_1, \dots, c_K)$, $\sum_{i=1}^K c_i = 1$

$L(y_i, c)$ – функция потерь

$$\mathbf{Branch}(X_m, j, t) = |X_m| \cdot H(X_m) - |X_l| \cdot H(X_l) - |X_r| \cdot H(X_r)$$

Чтобы принять решение о разделении, необходимо сравнить значение информативности для исходного листа и для получившегося после разделения решающего пня. Чем больше уменьшение неоднородности – тем лучше предполагаемый сплит

Критерии информативности в задачах регрессии

- MSE – регрессия с минимизацией квадратичной ошибки.

$$H(X_m) = \sum_{(x_i, y_i) \in X_m} \frac{(y_i - \bar{y})^2}{|X_m|}, \bar{y} = \frac{1}{|X_m|} \sum_i y_i$$

- MAE – регрессия с минимизацией абсолютной ошибки

$$H(X_m) = \sum_{(x_i, y_i) \in X_m} \frac{|y_i - \text{MEDIAN}(Y)|}{|X_m|}$$

Среднее и медиана считаются по объектам в текущем листе

Критерии информативности в задачах классификации

- Misclassification error – доля ошибок:

$$H(X_m) = \frac{1}{|X_m|} \sum_{(x_i, y_i) \in X_m} [y_i \neq k_*] = 1 - p_{k_*}$$

k_* - наиболее частый класс, p_{k_*} - доля объектов класса k в текущей вершине X_m

- Энтропия распределения классов (информационная энтропия Шеннона, измеряет непредсказуемость реализации случайной величины)

$$H(X_m) = - \sum_{k=1}^K p_k \log p_k$$


- Критерий Джини – $H(X_m)$ равно вероятности того, что случайно выбранный объект узла будет классифицирован неверно, если независимо назначить ему случайный класс согласно распределению классов в этом узле.

$$H(X_m) = \sum_{k=1}^K p_k(1 - p_k)$$



p_k - доля объектов класса k в узле X_m , K – число классов

Чем меньше значение, тем однороднее узел. Для узла с одним классом $H(X_m) = 0$


Жадное построение не гарантирует оптимального дерева



Оптимальное дерево



Дерево, построенное жадным алгоритмом



Критерий остановки


- Ограничение максимальной глубины дерева
- Ограничение минимального числа объектов в листе
- Ограничение максимального количества листьев в дереве
- Остановка в случае, если все объекты в листе относятся к одному классу
- Требование, что функционал качества при дроблении улучшался не ниже некоторого значения

Можно делать на разных этапах работы алгоритма:

- Pre-pruning (early stopping) – проверка критериев прямо во время построения дерева
- Pruning – строится переобученное дерево (без ограничений), а затем выполняется стрижка (pruning), то есть удаляются некоторые вершины из дерева так, чтобы итоговое качество упало не сильно, но дерево начало подходить под условия регуляризации. Гиперпараметры выбираются на valid / cross-validation.

- Cost-complexity pruning (ccp) – в функционал $R(T)$ вводится штраф α за размер дерева:

$R_\alpha(T) = R(T) + \alpha|T|$, где $|T|$ – число листьев в дереве



Работа с особенностями данных

Категориальные признаки

1. Разбивать вершину на k поддеревьев по количеству возможных значений у признака (может получиться крайне большое количество листьев)
2. Упорядочить по неубыванию доли объектов класса с $x^i = c_m$, после чего работать с ними, как со значениями вещественного признака – разделяя на значения, не превосходящие и большие определенного порога. Не нужен полный перебор. Для задачи регрессии с функцией потерь MSE значения c_m можно упорядочивать по среднему значению таргета

Обработка пропущенных значений

- При вычислении функционала делается поправка на потерю информации от исключения объектов с пропущенными признаками. Затем объекты помещаются как в левое, так и правое поддерево, им присваиваются веса, пропорциональные числу обучающих объектов в обоих поддеревьях. Прогнозы вычисляются в обоих поддеревьях и затем усредняются весами. Можно также использовать вероятность распределения классов
- Замена пропущенных значений либо на нулевое значение, либо на значения, которые превышают любое значение данного признака. Для категориальных переменных можно добавить новую категорию «пропущено»

Методы построения деревьев

- ID3 (Iterative Dichotomiser 3): использует энтропийный критерий. Строит дерево до тех пор, пока в каждом листе не окажутся объекты одного класса, либо пока разбиение вершины дает уменьшение энтропийного критерия
- C4.5 – использует критерий Gain Ratio (нормированный энтропийный критерий). Критерий остановки – ограничение на число объектов в листе. Pruning производится с помощью метода Error-based Pruning, который использует оценки обобщающей способности для принятия решения об удалении вершины. Обработка пропущенных значений осуществляется с помощью метода, который игнорирует объекты с пропущенными значениями при вычислении критерия ветвления, а затем переносит такие объекты в оба поддерева с определенными весами
- CART (Classification And Regression Tree) – использует критерий Джини. Pruning с помощью Cost-Complexity Pruning

Преимущества и недостатки решающих деревьев

- ✓ Интерпретируемость
- ✓ Возможность обработки пропусков в данных и категориальных признаков
- ✓ Не требуют нормализации данных
- ✓ Восстановление нелинейных зависимостей
- ✓ Эффективно работают с большими объемами данных
- × Склонность к переобучению, неустойчивость
- × Ограниченное качество классификации
- × Недостаточная эффективность при наличии трендов