

Тверской государственный технический университет

Интеллектуальные информационные системы

Ансамблевые методы

2026 г.

Идея ансамблирования – как объединить слабые по отдельности модели, чтобы получить более точную и устойчивую модель ?



Bias-Variance decomposition

Рассмотрим на примере: *функционал оценки качества работы алгоритма a при использовании квадратичной функции потерь:*

$$\boldsymbol{Q(a) = \mathbb{E}_x \mathbb{E}_{X,\epsilon}[y(x,\epsilon) - a(x,X)]^2}$$

$\boldsymbol{X}$ – обучающая выборка

$\boldsymbol{x}$ – объект из тестовой выборки

$\boldsymbol{y = f(x) + \epsilon}$ – целевая зависимость, измеренная с точностью до случайного шума $\boldsymbol{\epsilon}$

$\boldsymbol{a(x,X)}$ – значение алгоритма на объекте x

$\mathbb{E}_{\boldsymbol{x}}$ - математическое ожидание по всем объектам тестовой выборки

$\mathbb{E}_{\boldsymbol{X},\boldsymbol{\epsilon}}$ - математическое ожидание по всем обучающим выборка X и случайному шуму $\boldsymbol{\epsilon}$

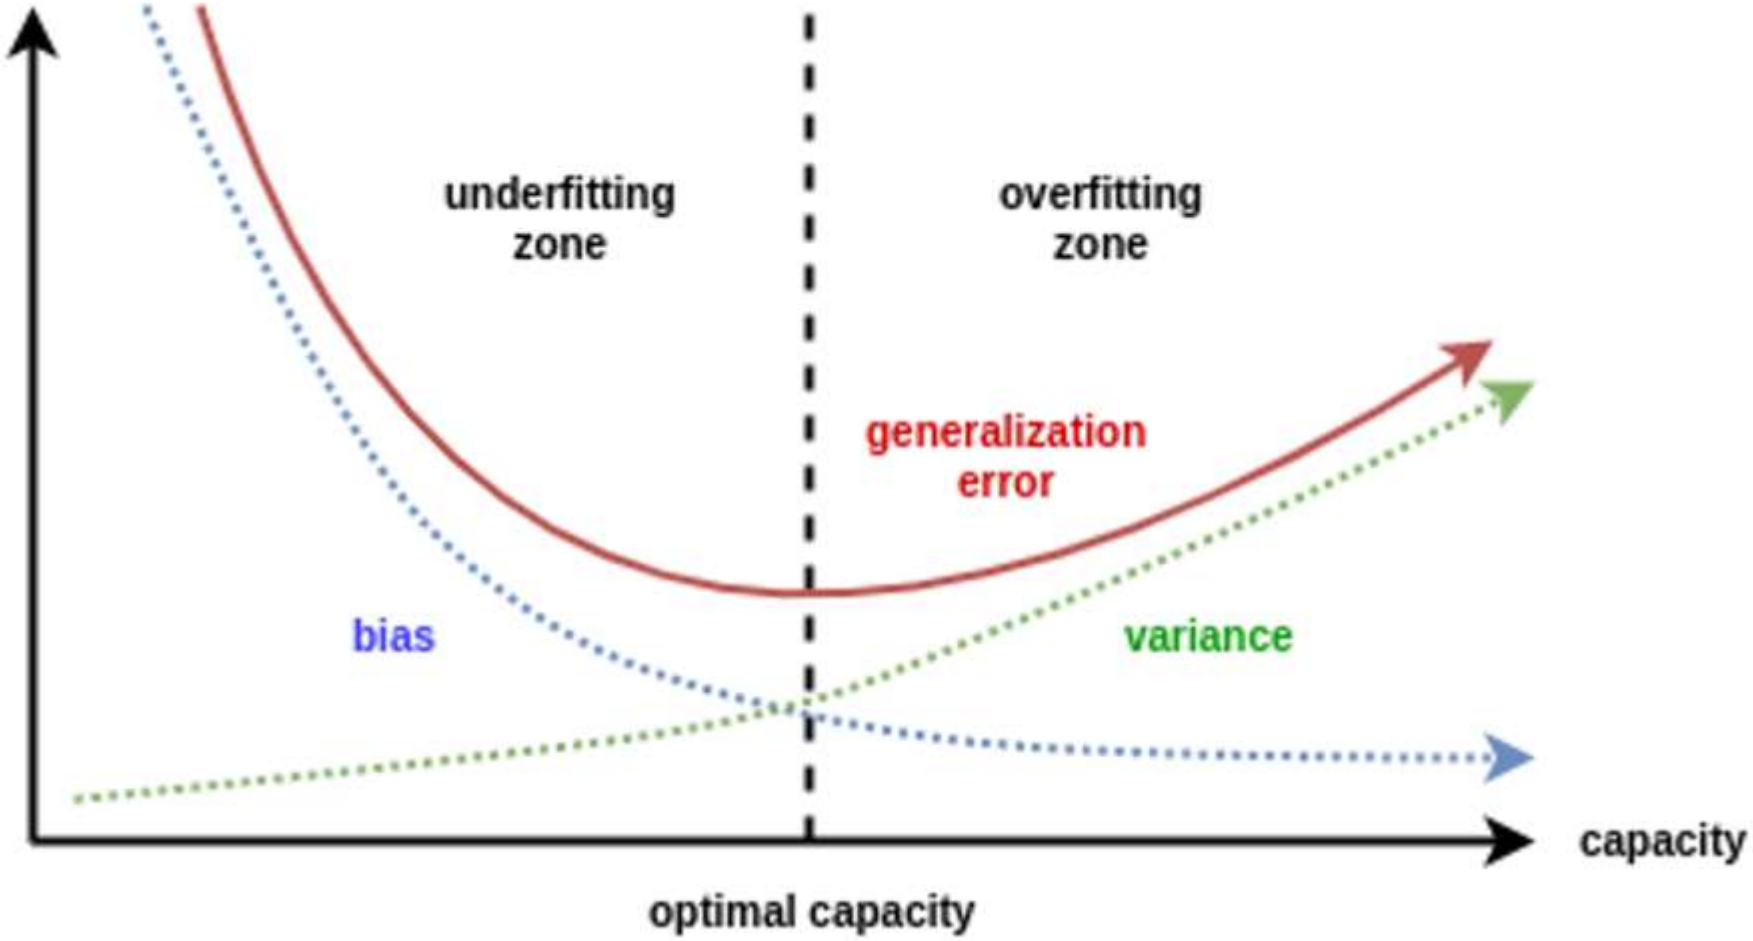
Представим этот же функционал в виде трех составляющих: шум, *смещение (bias)* и *разброс (variance)*

$$\boldsymbol{Q(a) = \mathbb{E}_x bias_X^2 a(x, X) + \mathbb{E}_X \mathbb{V}_X [a(x, X)] + \sigma^2}$$

$\boldsymbol{bias_X a(x, X) = f(x) - \mathbb{E}_X [a(x, X)]}$ - *смещение* предсказания алгоритма на объекте x, усредненного по всем возможным обучающим выборкам, относительно истинной зависимости f

$\boldsymbol{\mathbb{V}_X [a(x, X)] = \mathbb{E}_X \left[a(x, X) - \mathbb{E}_X [a(x, X)]^2\right]}$ - разброс (дисперсия) предсказаний алгоритма в зависимости от обучающей выборки X

$\boldsymbol{\sigma^2}$ - шум в данных

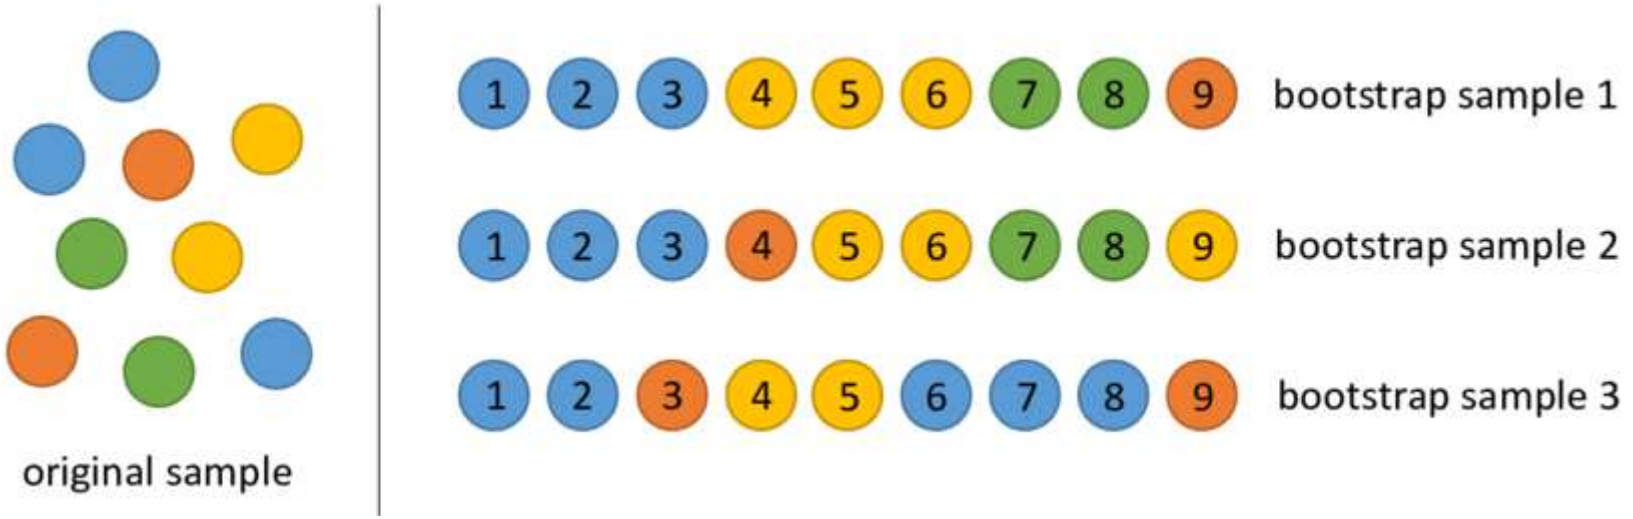

underfitting
zone
overfitting
zone
generalization
error
bias
variance
capacity
optimal capacity

Гипотеза: возможно ли уменьшить одну из компонент ошибки, не увеличивая другую?

Bootstrap

$X = (x_i, y_i)$ – конечная выборка размером ℓ

Сгенерируем N подвыборок $X_1, \ldots, X_N$ размером ℓ с помощью бутстрапа – выбираем ℓ объектов равновероятно с возвращением.



На каждой из подвыборок обучим модель, например, линейной регрессии, получив *базовые алгоритмы* $b_1(x), \dots, b_N(x)$. Существуют истинная функция ответа для всех объектов y(x) и задано распределение на объектах p(x). Тогда ошибка каждой функции регрессии:

$$\boldsymbol{\varepsilon_j(x) = b_j(x) - y(x), \qquad j = 1, \dots, N}$$

Математическое ожидание среднеквадратичной ошибки:

$$\boldsymbol{\mathbb{E}_X(b_j(x) - y(x))^2 = \mathbb{E}_X \varepsilon_j^2(x)}$$

Тогда средняя ошибка построенных функций регрессии:

$$E_1 = \frac{1}{N} \sum_{j=1}^{N} \boldsymbol{\mathbb{E}_x \varepsilon_j^2(x)}$$

Предположим, что ошибки несмещены и некоррелированы:

$\mathbb{E}_x \boldsymbol{\varepsilon_j}\,(\boldsymbol{x}) = 0$ *и* $\mathbb{E}_x \boldsymbol{\varepsilon_i}\,(\boldsymbol{x})\boldsymbol{\varepsilon_j}\,(\boldsymbol{x}) = 0, i \neq j$

Тогда новая функция регрессии, которая будет усреднять ответы построенных моделей:

$$a(x) = \frac{1}{N}\sum_{j=1}^{N} b_j(x)$$

Выведем среднеквадратичную ошибку этой функции:

$$E_N = \mathbb{E}_x\left(\frac{1}{N}\sum_{j=1}^{n} b_j(x) - y(x)\right)^2 = \mathbb{E}_x\left(\frac{1}{N}\sum_{j=1}^{N} \varepsilon_j\,(x)\right)^2$$

$$= \frac{1}{N^2}\,\mathbb{E}_x\left(\sum_{j=1}^{N} \varepsilon_j^2(x) + \sum_{i\neq j} \varepsilon_i\,(x)\varepsilon_j\,(x)\right) = \boxed{\frac{1}{N}E_1}$$

=0

Ошибка уменьшилась в N раз !

Предположим, что ошибки ~~несмещены и некоррелированы~~:

~~$\mathbb{E}_x \varepsilon_j(x) = 0$ и $\mathbb{E}_x \varepsilon_i(x)\varepsilon_j(x) = 0, i \neq j$~~

Тогда новая функция регрессии, которая будет усреднять ответы построенных моделей:

$$a(x) = \frac{1}{N}\sum_{j=1}^{N} b_j(x)$$

Выведем среднеквадратичную ошибку этой функции:

$$E_N = \mathbb{E}_x\left(\frac{1}{N}\sum_{j=1}^{n} b_j(x) - y(x)\right)^2 = \mathbb{E}_x\left(\frac{1}{N}\sum_{j=1}^{N} \varepsilon_j(x)\right)^2$$

$$= \frac{1}{N^2}\mathbb{E}_x\left(\sum_{j=1}^{N} \varepsilon_j^2(x) + \sum_{i\neq j} \varepsilon_i(x)\varepsilon_j(x)\right) = \boxed{\frac{1}{N}E_1}$$

$\sum_{i\neq j} \varepsilon_i(x)\varepsilon_j(x)$ = 0

Ошибка уменьшилась в ~~N~~ раз !

Bagging = bootstrap aggregating

Bagging – простое (не взвешенное) голосование

Обучаем некоторые число базовых алгоритмов $b_n(x)$ с помощью бутстрапирования выборки и строим итоговую композицию как среднее всех базовых алгоритмов (моделей):

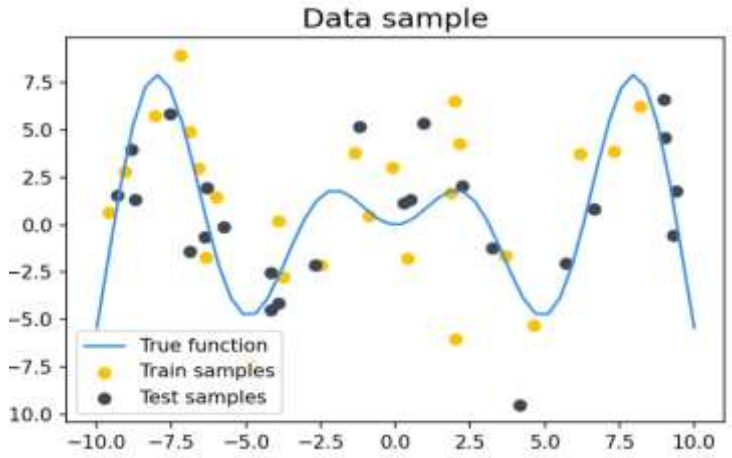
$$a_N(x) = \frac{1}{N}\sum_{n=1}^{N} b_n(x)$$

Оценим смещение и разброс ансамбля базовых алгоритмов (матожидание оцениваем по всем возможным подвыборкам, получаемым с помощью бутстрапа):

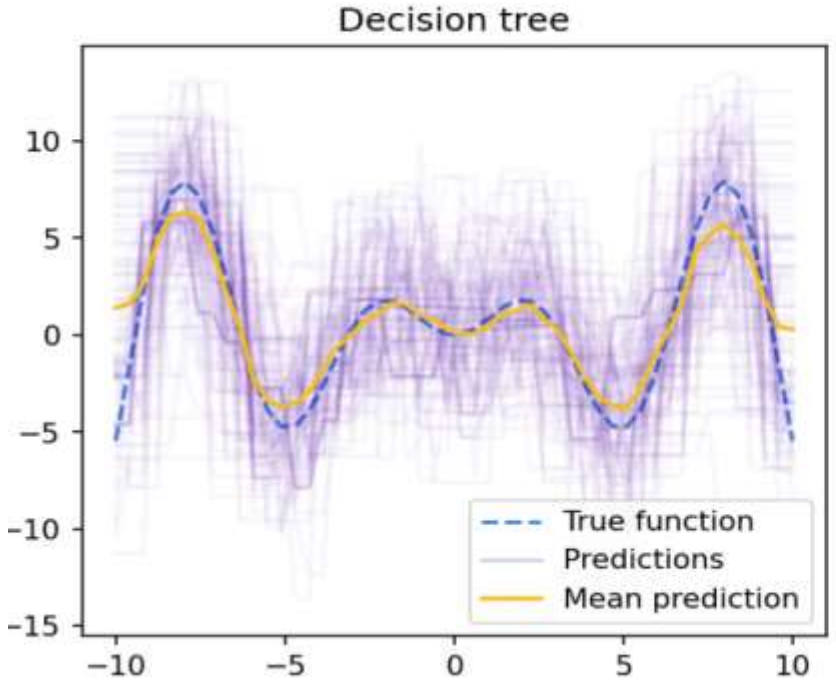
$bias_X a(x, X) = bias_X b(x, X)$ - смещение не изменилось по сравнению со средним смещением отдельных моделей (смещение ансамбля равно смещению одного алгоритма)

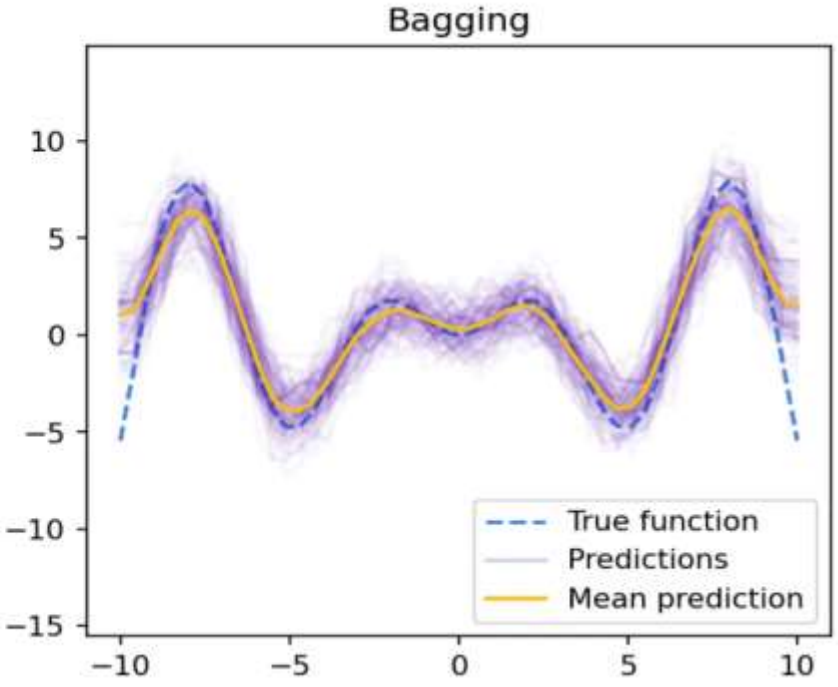
$\mathbb{V}_X[a(x, X)] = \frac{1}{N}\mathbb{V}_X b(x, X)$ – если базовые алгоритмы *некоррелированы*, то дисперсия ансамбля уменьшается в *N* раз

Бэггинг над решающими деревьями

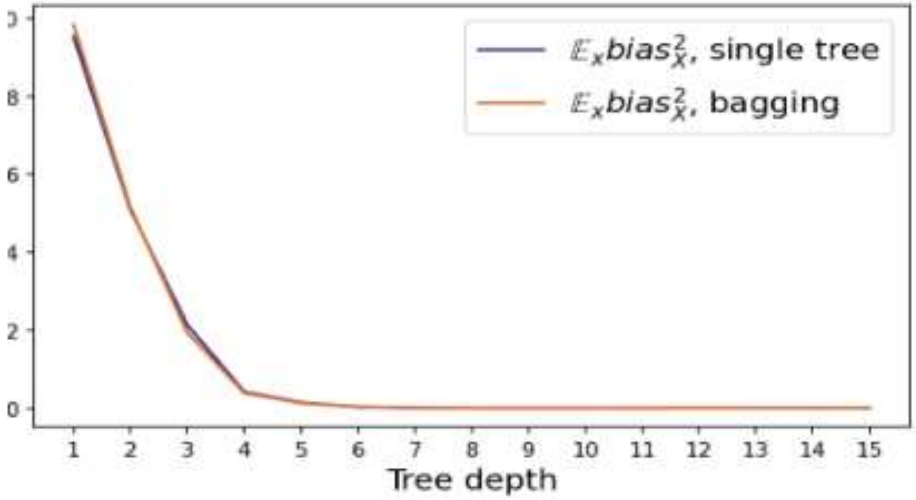


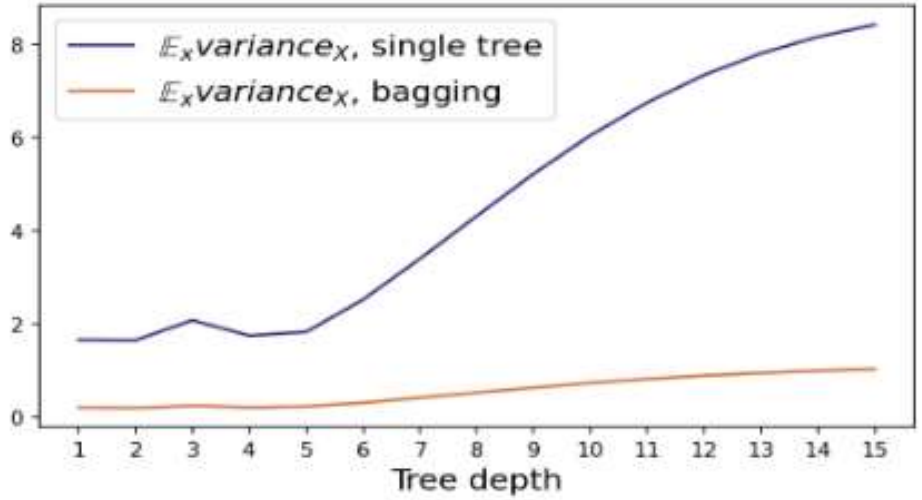
Общая дисперсия предсказаний в зависимости от обучающего множества у бэггинга значительно ниже, чем у отдельных деревьев, а в среднем их предсказания не отличаются

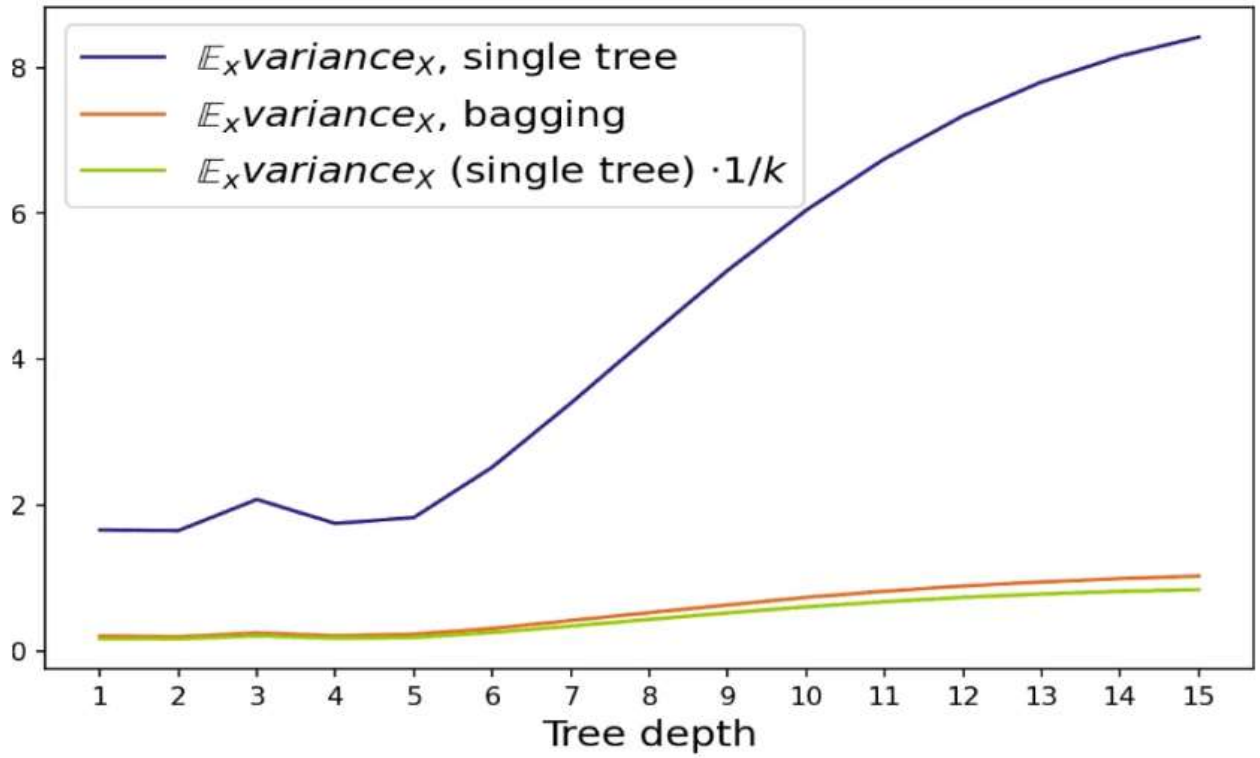




Источник: https://education.yandex.ru/handbook/ml/article/ansambli-v-mashinnom-obuchenii

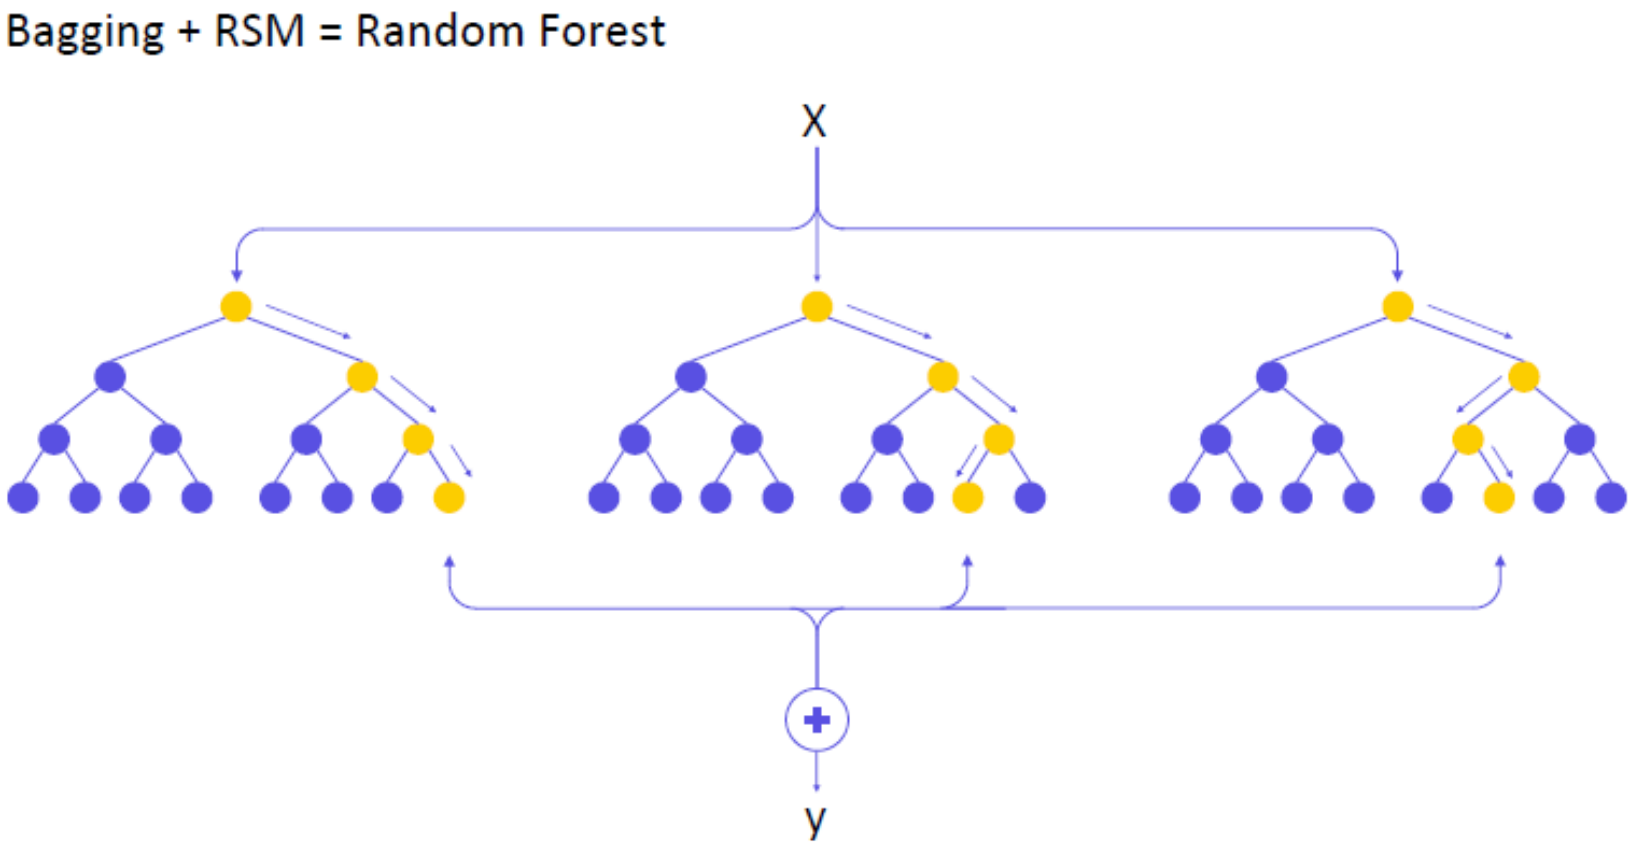

$\mathbb{E}_x bias^2_X$, single tree
$\mathbb{E}_x bias^2_X$, bagging
Tree depth


$\mathbb{E}_x variance_X$, single tree
$\mathbb{E}_x variance_X$, bagging
Tree depth


$\mathbb{E}_x variance_X$, single tree
$\mathbb{E}_x variance_X$, bagging
$\mathbb{E}_x variance_X$ (single tree) $\cdot 1/k$
Tree depth

Random forest

Метод случайных лесов – основан на бэггинге над решающими деревьями и методе случайных подпространств (random subspace method)



1. Для построения *i-го* дерева:

- из обучающей выборки X выбирается с возвращением случайная подвыборка X^i того же размера, что и X (бэггинг)

- в процессе обучения каждого дерева в каждой вершине случайно выбираются n < N признаков, где N – полное число признаков (метод случайных подпространств), и среди них ищется оптимальный сплит

2. Получение предсказания ансамбля на тестовом объекте: для регрессии – усредняем отдельные ответы деревьев, для классификации – выбираем самый популярный класс

Out-of-Bag

Объекты, которые не вошли в бустрапированную выборку X_n дерева b_n являются контрольными для данного дерева. Для каждого объекта x_i можно выбрать деревья, которые были обучены без него и вычислить по их ответам несмещенную out-of-bag-ошибку:

$$OOB = \frac{1}{l}\sum_{i=1}^{l} L\left(y_i, \frac{1}{\sum_{n=1}^{N}[x_i \notin X_n]}\sum_{n=1}^{N}[x_i \notin X_n]\, b_n(x_i)\right)$$

По мере увеличения числа деревьев N данная оценка стремится к leave-one-out оценке, но существенно проще для вычисления. По OOB оценке можно настраивать гиперпараметры Random Forest.

Bagging – в каждую выборку попадает $1 - \left(1 - \frac{1}{l}\right)^l \to 1 - \frac{1}{e} \approx 63.2\%$ объектов при $l \to \infty$

Особенности построения Random Forest

- Строим глубокие деревья, потому что у них низкое смещение, а разброс уменьшается за счет бэггинга.
- Чем больше признаков, тем больше корреляция между деревьями. По умолчанию – для регрессии [n/3] признаков, для классификации $\sqrt{n}$
- Количество деревьев в случайном лесе:

- выбираем исходя из зависимости уменьшения ошибки ансамбля от количества деревьев (строим график и смотрим когда ошибка перестает значимо уменьшаться)

- ограничиваем исходя из требований к времени работы модели

- Минимальное число объектов в расщепляемой подвыборке
- Минимальное число объектов в листьях
- Критерий расщепления (информативности)

Преимущества и недостатки стохастических методов ансамблирования

- ✓ Ансамблирование это *метод обертка* над базовым методом обучения (базовые алгоритмы обучаются готовыми методами)
- ✓ Универсальность – подходит для классификации, регрессии, поиска аномалий и других задач
- ✓ Простая реализация, легкое распараллеливание, т.к. все базовые алгоритмы строятся независимо
- ✓ Возможность получения несмещенных оценок OOB
- ✓ Random Forest – один из лучших универсальных методов, часто используется как baseline-решение с хорошим качеством, которое легко реализовать «из коробки»

- × Требуется большое количество базовых алгоритмов
- × Базовые алгоритмы должны быть разнообразными – необходимо найти компромисс качество/различность
- × Random forest плохо работает с разреженными признаками